TP : Prétraitement des données

Normalisation, standardisation et encodage des variables catégorielles

Filière	Data Analyst	**Durée indicative**	1h 30
Support	Python / Pandas / Scikit-learn	**Fichier**	jeu_donnees_clients_banque_100_lignes.xlsx

1. Contexte

Une banque souhaite exploiter les informations relatives à ses clients et prospects afin de préparer ses données pour une future analyse ou un modèle de Machine Learning. Le fichier fourni contient des informations numériques et catégorielles : âge, revenu annuel, solde bancaire, ancienneté, ville, profession, niveau d'études, satisfaction et statut.

Les variables sont exprimées dans des unités différentes et certaines catégories possèdent un ordre naturel, tandis que d'autres n'en possèdent pas. Le jeu de données comporte également quelques valeurs manquantes qui doivent être repérées avant les transformations.

Partie A – Chargement et exploration des données

1. Importer Pandas et charger la feuille « Donnees_Clients » du fichier Excel dans un DataFrame.

2. Afficher les 10 premières lignes, le nombre de lignes et de colonnes, ainsi que les noms des variables.

3. Afficher les types des variables et produire un résumé statistique des variables numériques.

4. Calculer le nombre de valeurs manquantes pour chaque colonne.

5. Classer les variables en quatre groupes : identifiant, numérique, nominale et ordinale. Justifier le classement.

Partie B – Normalisation Min-Max

Les variables numériques ne présentent pas les mêmes échelles. La normalisation Min-Max consiste à ramener les valeurs dans l'intervalle [0, 1].

1. Sélectionner les variables Age, Revenu_annuel_DH, Solde_DH et Anciennete_mois.

2. Vérifier et traiter les valeurs manquantes de ces variables avant d'appliquer le scaler. Indiquer la méthode retenue et la justifier.

3. Appliquer MinMaxScaler aux variables numériques sélectionnées.

4. Afficher les premières lignes du résultat et vérifier les minimums et maximums obtenus.

5. Expliquer l'effet de la normalisation sur les unités de mesure et sur les valeurs négatives éventuelles.

Partie C – Standardisation

1. À partir des données numériques préparées, appliquer StandardScaler.

2. Afficher les premières lignes des variables standardisées.

3. Calculer la moyenne et l'écart-type de chaque variable après transformation.

4. Comparer les résultats de StandardScaler et de MinMaxScaler.

5. Citer deux algorithmes ou situations où la mise à l'échelle des variables peut être utile.

Partie D – Encodage des variables nominales

Les variables Ville et Profession sont nominales : leurs catégories ne représentent pas un classement.

1. Identifier les catégories distinctes de Ville et de Profession.

2. Appliquer OneHotEncoder à ces deux variables.

3. Afficher les noms des colonnes créées et les premières lignes de la matrice encodée.

4. Préciser le nombre de nouvelles colonnes générées.

Partie E – Encodage des variables ordinales

Les variables Niveau_etudes et Satisfaction présentent un ordre logique. L'ordre doit être défini explicitement.

Variable	Ordre à respecter
Niveau_etudes	Bac < Licence < Master < Doctorat
Satisfaction	Faible < Moyenne < Élevée < Très élevée

1. Définir les catégories dans le bon ordre avec OrdinalEncoder.

2. Transformer Niveau_etudes et Satisfaction en valeurs numériques.

3. Afficher les valeurs originales et encodées pour quelques lignes.

4. Expliquer la différence entre un encodage nominal et un encodage ordinal.

Partie F – Synthèse et analyse

1. Construire un tableau récapitulatif indiquant, pour chaque variable, son type et la transformation appliquée.

2. Comparer le nombre de colonnes avant et après One-Hot Encoding.

3. Expliquer pourquoi l'identifiant ID_Client ne doit généralement pas être utilisé comme variable explicative.

4. Expliquer pourquoi les paramètres des transformations doivent être calculés sur les données d'entraînement uniquement lorsqu'on construit un modèle prédictif.

5. Proposer un ordre logique des opérations à effectuer avant d'entraîner un modèle de Machine Learning.

Livrables

- Un notebook ou un script Python commenté.
- Un tableau de synthèse des variables et des méthodes de prétraitement.
- Un court paragraphe comparant normalisation et standardisation.
- Les résultats des encodages nominal et ordinal.